AIE 403 정보 검색 프로젝트 과제

검색 시스템 구현: 커피 stack exchange data 를 사용하여 [구현 1], [구현 2], [구현 3]에 설명된 검색 시스템을 구현하라.

제출 :

- **제출처: 가상대학(LMS) 의 과제**
- **정상 제출 기한:** 2026 년 6 월 5 일(금) 23:59
- **지각 제출 기한:** 2026 년 6 월 10 일(수) 23:59
- **제출물:** 프로그램 소스 코드와 보고서

- **(1)프로그램 소스 코드 (70 점)**
  - 소스코드는 파이선 소스 코드를 zip 으로 압축하여 제출.
    (colab 등 사용하지 말고 일반 python 파일 제출)
  - 코드는 에러 없이 실행할 수 있어야 함.
- **(2) 보고서 (30 점)**
  - 보고서 파일은 pdf 파일로 제출.
  - 보고서 파일에는 코드 실행 방법이 상세히 적혀 있어야 함.
    - 보고서 파일 내용대로 실행하였으나 코드가 실행되지 않은 경우 코드 점수 0 점
  - 보고서 내용은 다음 [구현 1], [구현 2], [구현 3]에 대한 실행결과와 질문에 대한 논의를 포함해야 함

주의사항:

▪ **개인과제**. Copy 적발 시 첫 시간 강의소개 자료의 규정에 따름

▪ [구현 1, 2, 3] 중 하나라도 구현한 경우 과제 제출한 것으로 처리 (성적 Grade down 적용하지 않음)

▪ [구현 1, 2, 3] 모두 구현 못한 경우, 20 페이지 이상 공부한 내용을 **손으로 정리**하여 제출하면 과제 점수는 0 점이나 성적 Grade down 은 적용하지 않음.

▪ **[구현 1, 2, 3 공통사항: 문서 만들기]**

- Post.xml 파일은 pandas 를 사용하여 parsing 가능
- 하나의 질문 포스팅에 대해 그에 대한 모든 답변 포스팅을 묶어서 하나의 문서로 취급
  - 예) "질문: 블랙 커피 어떻게 만들어요?" 에 두 답변 "답변 1.커피로 만들어요", "답변 2. 설탕을 안 넣어요" 가 있다면 "블랙 커피 어떻게 만들어요? 커피로 만들어요 설탕을 안 넣어요"가 하나의 문서
- 포스팅의 내용은 title 과 body 의 내용을 더한 것으로 정의
  - 예)title: "질문: 블랙 커피 어떻게 만들어요?" body: "제가 블랙 커피를 만들고 싶어요. 어떻게?" 라면 우리가 취급할 내용은 "블랙 커피 어떻게 만들어요? 제가 블랙 커피를 만들고 싶어요. 어떻게?"

포스팅 xml 필드 이름	설명
Id	포스팅 ID
PostTypeID	포스팅 종류. 1 이면 질문, 2 이면 답변
ParentID	포스팅이 답변일 경우, 질문의 ID
Title	포스팅 타이틀
Body	포스팅 내용

- 대문자는 모두 소문자로 표현할 것, NLTK (https://www.nltk.org/)를 사용하여 Tokenize 및 Lemmatize 할 것
- Inverted Index 구현 시 stop-word (https://www.ranks.nl/stopwords 혹은 NLTK 사용)와 문장 부호(. , - ; : ' " 등)는 제거할 것
- 입출력을 위해 GUI 를 만들 필요는 없음. 입력은 command line 으로 받고, 출력은 screen 에 print 하면 충분함.

[구현 1, 40 점] Inverted Index 를 사용하여 term 출현 빈도 기반 ranking 구현

커피 stack exchange data (Post.xml)의 포스팅을 사용하여 각 term 의 출현횟수가 저장된 Inverted Index 를 구현하고 이를 사용한 검색 시스템을 구현하라

▪ 쿼리를 구성하는 term 의 문서에서의 출현 빈도(점수)는 각 term 에 대한 출현 빈도의 합으로 계산하라

$$R(Q,D) = \sum_{t \in Q \cap D} tf_{t,D}$$

Q: query, D: 문서, $tf_{t,D}$: 문서 D 에서의 term t 의 출현횟수.

예1) **Query**: "Black Coffee" 이고 "문서 1"에 "Black"이 4 회," Coffee"가 2 회 나타났을 경우 문서 1 의 Query 에 대한 점수는 4+2 = 6 점

예2) **Query**: "Black Coffee" 이고 "문서 2"에 "Black"만 4 회," 나타났을 경우 문서 2 의 Query 에 대한 점수는 4 점

[질문 1] Table 1 의 세 쿼리 각각에 대해 top-5 개의 검색 결과(문서)를 랭킹 순서대로 테이블로 정리하여 표시 (검색 문서의 글이 너무 많은 경우 앞 20 단어만 표시) 한 다음 Table 2 의질문에 답하라.

Table 1

No	쿼리	Information Need
1	Espresso	*how to make espresso?*
2	Turkish coffee	*making Turkish coffee*
3	Persian coffee	*making Persian coffee*

Table 2

질문	비고
-검색해 온 Top 5 개 문서 중에서 쿼리와 관련 깊은 문서는 몇 개이며 각각의 문서는 왜 그렇게 판단했는가?	-"제대로 검색된"을 판단하는 기준은 본인의 기준을 적용하라.

[구현 2, 30 점] TF-IDF 랭킹 구현

앞서 구현한 코드를 확장하여 TF-IDF 랭킹을 구현하라

- 문서 D 의 쿼리 Q 에 대한 TF-IDF 스코어 식은 다음 식을 사용하여라

$$Score(Q,D) = \sum_{t \in Q \cap D} tfidf_{t,d} \quad \text{(식 1)}$$

$$tfidf_{t,D} = w_{t,D} * idf_t \quad \text{(식 2)}$$

$$w_{t,D} = \begin{cases} 1 + \log_e tf_{t,D}\,, & if\ xtf_{t,D} > 0 \\ 0, & otherwise \end{cases} \quad \text{(식 3)}$$

$$idf_t = \log_2\left(\frac{N}{df_t}\right) \quad \text{(식 4)}$$

$\boldsymbol{Q}$: term 의 집합으로 표현된 query

$\boldsymbol{D}$: term 의 집합으로 표현된 document

$\boldsymbol{tf_{t,D}}$: term t 가 document D 에 나타나는 횟수

$\boldsymbol{df_t}$: term t 가 한 번이라도 나타나는 document 의 개수

$\boldsymbol{N}$**:** 전체 document 개수

예) Query Q: "Black Coffee"이고, 문서 D1 의 $tfidf_{black,d1}$이 2.5, $tfidf_{coffee,d1}$이 1.5 이면 D1 의 점수(Score(Q, D1))는 식 (1)에 의해 2.5+1.5 = 4.0

[질문 2] Table 1 의 세 쿼리 각각에 대해 top-5 개의 검색 결과(문서)를 랭킹 순서대로 테이블로 정리하여 표시 (검색 문서의 글이 너무 많은 경우 앞 20 단어만 표시) 한 다음 Table 2 의 질문에 답하라. **(구현 1 과 동일하게 평가)**

[구현 3, 30 점] Vector Space Model 랭킹 구현

앞서 구현한 코드를 **확장하여 Vector Space Model 랭킹**을 구현하여라. Euclidean Distance 와, Cosine Similarity 를 유사도 계산에 사용한 랭킹, 총 2 가지를 모두 구현하라.

- 각 document 를 나타내는 bag-of-words 벡터의 각 Element(term)에 들어갈 값은 구현 2 의 (식 1)에서 계산한 $\boldsymbol{tfidf_{t,d}}$값 (식 2)을 사용하라

[질문 3] Table 3 의 세 쿼리 각각에 대해 top-5 개의 검색 결과(문서)를 랭킹 순서대로(Euclidean Distance, Cosine Similarity 각각) 테이블로 정리하여 표시 (검색 문서의 글이 너무 많은 경우 앞 20 단어만 표시) 한 다음 Table 4 의질문에 답하라.

Table 3

No	쿼리	Information Need
1	Espresso	*how to make espresso?*
2	Turkish coffee	*making Turkish coffee*
3	making a decaffeinated coffee	*making a decaffeinated coffee*
4	can I use the same coffee grounds twice?	*can I use the same coffee grounds twice?*

Table 4

질문	비고
- Top 5 개 중에 Information need 에 비추어 쿼리와 관련 깊은 문서를 판단하고, 왜 그렇게 판단했는지를 논하라.	-“제대로 검색된”을 판단하는 기준은 본인의 기준을 적용하라.
Cosine similarity 비교와 Euclidean distance 비교 중 무엇이 더 결과가 좋아 보이는가? 그 이유는?	